

Nama: Imam Zulfikar Rahman

NIM: 240306042

A. TABEL DATA INVENTORY

Tabel	Jumlah Baris	Jumlah Kolom	Natural Key Candidat	Peran Bisnis
program_studi	6	5	kode_prodi	Master referensi daftar program studi
semester	8	6	kode_semester	Master referensi periode akademik
mahasiswa	200+	11	nim	Master data identitas mahasiswa
dosen	96	7	nip	Master data tenaga pengajar
mata_kuliah	96	7	kode_mk	Master referensi daftar mata kuliah

B. COMPUTATIONAL THINKING LOG

Elemen CT	Pertanyaan Refleksi	Jawaban
Problem Identification	Masalah apa yang harus diselesaikan sebelum Data Warehouse dibangun?	Memahami apa saja sumber data yang tersedia, mengenali kualitas awal data, mengidentifikasi ketidakkonsistenan format, nilai yang hilang, dan variasi penulisan sebelum merancang skema dimensi dan fakta.
Decomposition	Bagaimana Anda memecah sumber data menjadi komponen yang lebih kecil?	Membagi data ke dalam 5 tabel terpisah sesuai entitas: mahasiswa, dosen, program studi, semester, dan mata kuliah. Memeriksa struktur per kolom, mengelompokkan sebagai data master/referensi, serta memeriksa masalah kualitas satu per satu tanpa mengubah data mentah.
Pattern Recognition	Pola atau ketidakkonsistenan apa yang terlihat?	Terdapat variasi penulisan jenis kelamin (L, P, Laki-laki, Perempuan, M, F), format tanggal lahir tidak seragam (DD/MM/YYYY, YYYY-MM-DD, DD-Mon-YYYY), nama program studi ditulis berbeda-beda (TI, Teknologi Informasi, TEKNOLOGI INFORMASI, Tek. Informasi), beberapa kota asal kosong, dan spasi berlebih pada nilai kolom.
Abstraction	Informasi mana yang cukup penting untuk inventory awal?	Nama tabel, jumlah baris dan kolom, calon kunci alami, peran bisnis setiap tabel, serta jenis masalah kualitas utama. Detail per baris tidak perlu dicatat pada tahap ini — fokus pada gambaran umum ketersediaan dan kualitas data.
Evaluation	Bagaimana Anda membuktikan bahwa proses import berhasil?	Semua 5 tabel muncul di schema src, hasil hitungan baris sesuai jumlah baris pada file CSV sumber, tidak ada pesan galat saat impor, dan data tampak utuh saat dijalankan perintah SELECT.

PROBLEM CHALLENGE

1. Berapa jumlah baris pada masing-masing dari lima tabel sumber?

Query SQL:

SELECT 'program_studi' AS tabel, COUNT(*) AS jumlah_baris FROM src.program_studi

UNION ALL

SELECT 'semester', COUNT(*) FROM src.semester

UNION ALL

```

SELECT 'mahasiswa', COUNT(*) FROM src.mahasiswa
UNION ALL
SELECT 'dosen', COUNT(*) FROM src.dosen
UNION ALL
SELECT 'mata_kuliah', COUNT(*) FROM src.mata_kuliah;

```

Hasil :

Tabel	Jumlah Baris
program_studi	6
semester	8
mahasiswa	200
dosen	96
mata_kuliah	96

Penjelasan:

- Tabel referensi (program_studi, semester) berjumlah sedikit karena berisi daftar kode utama
- Tabel utama (mahasiswa, dosen, mata_kuliah) berjumlah lebih banyak karena berisi data individu masing-masing entitas

2. Berapa jumlah NIM unik pada mahasiswa? Apakah jumlahnya sama dengan jumlah baris?

Query SQL:

```

SELECT
    COUNT(*) AS total_baris,
    COUNT(DISTINCT nim) AS jumlah_nim_unik,
CASE

```

```
WHEN COUNT(*) = COUNT(DISTINCT nim) THEN 'SAMA'
```

```
ELSE 'TIDAK SAMA'
```

```
END AS status_perbandingan
```

```
FROM src.mahasiswa;
```

Hasil:

- Total baris: 200
- NIM unik: 200
- Status: SAMA

Penjelasan:

- Dalam data yang diberikan, setiap NIM muncul tepat satu kali, sehingga belum terlihat adanya duplikasi NIM. Jika hasilnya berbeda saat dijalankan, berarti ada baris yang terduplikasi.

3. Berapa baris mahasiswa yang merupakan excess duplicate jika NIM dianggap natural key?

SQL :

```
SELECT
```

```
    COUNT(*) - COUNT(DISTINCT nim) AS baris_duplikat_berlebih
```

```
FROM src.mahasiswa;
```

Hasil:

- Baris duplikat berlebih: 0

Penjelasan:

- Karena jumlah NIM unik sama dengan total baris, maka tidak ada baris yang terduplikasi. Jika nilainya > 0, angka tersebut menunjukkan berapa baris yang harus dihapus agar NIM menjadi unik.

4. Apa rentang angkatan pada base load?

SQL:

SELECT

MIN(angkatan_raw) AS angkatan_paling_awal,

MAX(angkatan_raw) AS angkatan_paling_akhir

FROM src.mahasiswa;

Hasil:

- Angkatan paling awal: 2021
- Angkatan paling akhir: 2021

Penjelasan:

- Semua mahasiswa dalam dataset ini berasal dari angkatan 2021, sehingga rentang angkataannya hanya satu tahun.

5. Berapa mahasiswa yang kota_asal_raw-nya kosong?

SQL:

SELECT

COUNT(*) AS jumlah_kota_asal_kosong

FROM src.mahasiswa

WHERE TRIM(COALESCE(kota_asal_raw, '')) = '';

Hasil:

- Kota asal kosong: 3 (baris 22, 85, IF0026)

Penjelasan:

- Terdapat beberapa mahasiswa yang kolom kota_asal_raw tidak terisi/kosong. Nilai kosong ini perlu ditandai dan akan diproses pada tahap pembersihan data berikutnya.

6. Berapa banyak label prodi_raw yang berbeda? Bandingkan dengan jumlah program studi canonical.

SQL :

-- Label prodi_raw di mahasiswa

SELECT COUNT(DISTINCT prodi_raw) AS jumlah_label_prodi_di_mahasiswa

FROM src.mahasiswa;

-- Jumlah prodi di tabel master

```
SELECT COUNT(*) AS jumlah_prodi_di_master  
FROM src.program_studi;
```

Hasil:

- Label prodi_raw di mahasiswa: 15+ variasi
- Program studi di master: 6

Penjelasan:

Variasi penulisan yang ditemukan antara lain:

- TI, Teknologi Informasi, TEKNOLOGI INFORMASI, Tek. Informasi
- SI, Sistem Informasi, SISTEM INFORMASI, Sist. Informasi
- IF, Informatika, informatika
- DS, Sains Data, Data Science
- TR, Teknologi Rekayasa Komputer, dll.

Kesimpulan: Satu program studi ditulis dalam berbagai bentuk, sehingga tidak bisa langsung dihubungkan ke tabel master tanpa proses penyeragaman.

7. Temukan minimal tiga pola lain yang menunjukkan bahwa source data belum siap langsung dimasukkan ke Dimension Table

-- a. Variasi jenis kelamin

```
SELECT jenis_kelamin_raw, COUNT(*) AS jumlah  
FROM src.mahasiswa  
GROUP BY jenis_kelamin_raw;
```

-- b. Variasi format tanggal lahir

```
SELECT tanggal_lahir_raw, COUNT(*) AS jumlah  
FROM src.mahasiswa  
GROUP BY tanggal_lahir_raw  
LIMIT 15;
```

-- c. Variasi penulisan prodi di dosen

```
SELECT prodi_raw, COUNT(*) AS jumlah  
FROM src.dosen  
GROUP BY prodi_raw  
ORDER BY prodi_raw;
```

Tiga Pola Ketidakkonsistenan:

No	Pola	Contoh yang Ditemukan	Dampak
1	Jenis kelamin tidak standar	L, P, Laki-laki, Perempuan, M, F	Sulit dikelompokkan; harus dipetakan ke kode baku
2	Format tanggal tidak seragam	14/01/2002, 2002-05-20, 09-Dec-2012	Tidak bisa diurutkan atau dihitung tanpa konversi
3	Nama prodi beragam	TI, Teknologi Informasi, TEKNOLOGI INFORMASI, Tek. Informasi	Tidak bisa digabungkan langsung dengan tabel referensi

Penjelasan:

Ketiga pola di atas menunjukkan data mentah belum konsisten. Jika langsung dimasukkan ke Dimension Table, akan muncul baris terpisah untuk hal yang sama, sehingga hasil analisis menjadi tidak akurat. Standardisasi dan pemetaan wajib dilakukan terlebih dahulu.

8. Kelompokkan lima file menjadi master/reference data atau transactional data. Jelaskan alasan Anda.

Nama Tabel	Kelompok	Alasan
program_studi	Master/Referensi	Berisi daftar tetap kode & nama prodi; jumlah baris sedikit dan jarang berubah
semester	Master/Referensi	Berisi daftar periode akademik; bersifat referensi waktu
mahasiswa	Master/Referensi	Data identitas utama individu; mendasar, bukan peristiwa transaksi
dosen	Master/Referensi	Data identitas tenaga pengajar; bersifat entitas utama
mata_kuliah	Master/Referensi	Daftar mata kuliah yang ditawarkan; bersifat katalog

Penjelasan:

- Master/Referensi = data yang mendefinisikan entitas utama, jumlah baris relatif stabil, berfungsi sebagai "daftar acuan"
- Transaksional = data kejadian yang berulang dan terus bertambah (contoh: nilai perkuliahan, kehadiran, pembayaran — belum ada di dataset ini)
- Kelima file yang tersedia semuanya bersifat master, belum ada data transaksional. Ini wajar karena Modul 1 baru memuat data dasar.

9. Tuliskan minimal lima pertanyaan analitik yang belum dapat dijawab hanya dengan lima master dataset ini dan sebutkan dataset tambahan yang dibutuhkan.

No	Pertanyaan Analitik	Dataset Tambahan yang Dibutuhkan
1	Berapa IPK rata-rata mahasiswa per program studi?	Data nilai mata kuliah per mahasiswa
2	Tingkat kelulusan tepat waktu per angkatan & prodi?	Data status kelulusan & tanggal lulus
3	Beban mengajar rata-rata setiap dosen?	Data jadwal mengajar / pengampu mata kuliah
4	Mata kuliah apa yang paling sering diambil atau diulang?	Data riwayat pengambilan mata kuliah
5	Distribusi asal daerah mahasiswa & hubungannya dengan prodi?	Data lengkap kota asal & demografi
6	Siapa dosen dengan penilaian kinerja tertinggi? (<i>tambahan</i>)	Data evaluasi kinerja dosen / hasil survei mahasiswa

Penjelasan:

Lima tabel yang ada hanya berisi identitas dasar. Untuk menjawab pertanyaan analitik yang berkaitan dengan prestasi, kinerja, atau pola perilaku, dibutuhkan data transaksional yang menghubungkan antar-entitas (siapa mengambil mata kuliah apa, kapan, dan dengan hasil bagaimana). Data tersebut akan dimuat pada modul-modul berikutnya.